

Data Science y Analytics en Servicios Financieros

Clase 01 – Introducción y Contexto

2026-06-24

Enlaces

-  segana@fen.uchile.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Estructura de la Sesión

Bloque	Duración	Contenido
1	20 min	Contexto y motivación: por qué importan los datos y la IA hoy
2	35 min	Decision Science: decisiones intuitivas vs. estructuradas, sesgos cognitivos
3	20 min	Framework organizacional: Decision Stack, triaging y calidad de datos
4	45 min	Los enemigos silenciosos de los datos + Actividad de diagnóstico (15 min)

Bloque 1: Contexto y motivación

Contexto actual

- El volumen global de datos crece a más de **40 % anual** (IDC, 2024).
- Sin embargo, solo **~30 %** de las empresas afirma ser realmente *data-driven* (McKinsey, 2023).
- El valor no está en acumular datos, sino en **transformarlos en decisiones**.
- La complejidad actual exige modelos predictivos, arquitecturas modernas y procesos guiados por evidencia.



Rol de la IA

- La IA permite **extraer patrones, predecir comportamientos y automatizar decisiones**.

- Integra datos estructurados y no estructurados (texto, audio, imágenes, PDFs, transacciones, logs).
 - Los modelos actuales (ML + LLMs) permiten:
 - Extraer señales desde fuentes no tradicionales.
 - Recuperar + generar contenido (RAG).
 - Acelerar la **velocidad y calidad** de las decisiones.
 - Objetivo central: **reducir incertidumbre** y mejorar resultados.
-

¿Por qué es difícil ser data-driven?

- No es un problema técnico: es un problema **organizacional y cultural**.
 - Obstáculos frecuentes:
 - Datos dispersos, desordenados o sin gobierno.
 - Falta de claridad en la decisión que se quiere mejorar.
 - Poca alineación entre áreas (TI, riesgo, operaciones, finanzas).
 - Sesgos humanos que dominan la toma de decisiones.
 - Baja adopción de modelos por parte del negocio.
 - Conclusión: ser data-driven requiere **procesos, cultura y diseño**, no solo modelos.
-

Bloque 2: Decision Science

Instituciones basadas en datos

La diferencia entre decisiones **intuitivas** y decisiones **basadas en datos** es crítica.

Ejemplo cotidiano:

Elegir entre dos ofertas laborales (mayor salario vs. mejor calidad de vida).

Podemos decidir por instinto o mediante una **evaluación sistemática** de factores.

Una organización data-driven hace lo mismo:

- define el problema
- recopila evidencia
- evalúa escenarios
- elige la opción con **mayor retorno esperado**
- reduce el espacio de incertidumbre

Este es el territorio de **Decision Science**.

¿Qué es Decision Science?

La *Decision Science* es el campo interdisciplinario que:

- Combina estadística, economía, psicología, modelos computacionales y negocio.
- Crea procesos estructurados para **mejorar decisiones bajo incertidumbre**.
- Traduce datos + modelos en **acciones concretas** que generan impacto.
- Permite diseñar decisiones que sean:
 - informadas,
 - repetibles,
 - medibles,
 - alineadas a objetivos estratégicos.

Idea clave:

Los datos no toman decisiones, las decisiones se diseñan.

Ejemplo cotidiano de decisión

Considera dos opciones:

- **Oferta A:** mayor salario, pero requiere relocalización.
 - **Oferta B:** menor salario, pero mejor equilibrio vida/trabajo.
-

¿Cómo decides?

Puedes:

Decisión intuitiva: Una decisión tomada desde el instinto: rápida, emocional, y dependiente de cómo te sientes en ese momento. No requiere estructura, pero puede ser difícil de justificar o repetir.

Decisión estructurada: Una decisión diseñada: define claramente qué factores importan (salario, familia, transporte, salud) y cómo se relacionan entre sí.

Permite comparar escenarios, pensar en los riesgos y visualizar los compromisos que implica cada alternativa.

Esto mismo escala al mundo financiero: aprobar un crédito, fijar un precio, asignar un portafolio. Todo requiere **criterios, escenarios, riesgo, datos**.

Sesgos más allá de los datos

Incluso con modelos y datos perfectos, los seres humanos tenemos sesgos que afectan la decisión:

- **Confirmation bias:** buscamos información que confirma lo que creemos.
 - **Anchoring bias:** nos quedamos anclados a un valor inicial (ej.: precio en un “cyber”).
 - **Loss aversion:** perder duele más que ganar lo mismo.
 - **Availability heuristic:** sobreestimamos eventos fáciles de recordar (accidentes aéreos).
-

Estos sesgos están presentes en:

- decisiones de riesgo
- inversiones
- evaluación de campañas
- aprobación de créditos

Decision Science busca mitigarlos mediante procesos estructurados.

Sobre la racionalidad limitada

La teoría asume decisiones racionales:

- información completa
 - tiempo infinito
 - sin emociones
 - sin sesgos
-

La realidad es distinta:

1. **Tenemos límites cognitivos.**
2. **Disponemos de información incompleta.**
3. **Operamos bajo presión de tiempo.**
4. **Emociones y riesgo percibido influyen.**

Por eso la toma de decisiones ocurre en un contexto de **racionalidad limitada**, donde los modelos y los datos ayudan a compensar nuestras limitaciones.

El método científico como base

El método científico propone un ciclo estructurado:

1. **Observación**
 2. **Planteamiento de hipótesis**
 3. **Experimentación / Medición**
 4. **Análisis de resultados**
 5. **Conclusión**
-

En Decision Science este ciclo se aplica a decisiones:

- Las hipótesis = propuestas de acción.
- Los experimentos = pilotos, A/B testing, simulaciones.
- El análisis = evidencia cuantitativa sobre qué funciona.

No se trata de “tener razón”, sino de **aprender**.

Toda decisión es una predicción

Cada decisión —en salud, finanzas o negocios— implica una predicción:

- Aprobar un crédito → predicción de pago/no pago.
 - Determinar un precio → predicción de demanda.
 - Asignar un portafolio → predicción de retornos y riesgos.
 - Aceptar un trabajo → predicción de bienestar futuro.
-

Una buena decisión requiere:

- datos
- modelos
- escenarios
- estimar incertidumbre
- medir impacto

El reto no es decidir, sino predecir mejor. Y hacerlo de forma sistemática.

Bloque 3: Framework organizacional

The Decision Stack

Para que los datos generen impacto, se debe comenzar **arriba**, en la decisión:

1. **Decision**

- ¿Qué decisión específica vamos a mejorar?

2. **Objective**

- ¿Qué significa “mejor”?
- ¿Mayor retorno? ¿Menor riesgo? ¿Mayor conversión?

3. **Alternatives**

- Distintas políticas, reglas, modelos, precios.
-

4. **Uncertainty**

- ¿Qué no sabemos?
- ¿Cómo lo cuantificamos?

5. **Models**

- Herramientas para reducir incertidumbre.

6. **Data**

- Datos como insumo, no como punto de partida.

7. **Action**

- Implementación y monitoreo.

Idea clave: Los proyectos exitosos empiezan por la **decisión**, no por los datos. En la práctica, esto se traduce en un ciclo simple: **definir el problema → reunir y priorizar datos → evaluar alternativas → implementar y medir**.

Triaging y calidad de datos

No todos los datos valen la pena: hay que priorizar los que tengan **impacto potencial, disponibilidad, costo razonable y alineación con la decisión** — y validar que estén completos, vigentes y libres de outliers antes de usarlos.

Buenos datos → buenos modelos → mejores decisiones. (Más adelante veremos qué falla cuando esto no se cumple.)

¿Por qué fallan los proyectos data-driven?

Las causas más comunes:

Problema	Descripción
Problema mal definido	Modelo construido sin una decisión clara asociada
Métricas de éxito poco claras	Éxito técnico no coincide con el éxito de negocio
Mala calidad de datos	Datos desordenados, incompletos o irrelevantes
Desconexión entre negocio y analytics	Poco buy-in, alineación débil, expectativas poco realistas
Modelos que no se implementan	Quedan en notebooks y no llegan a producción
Falta de cultura de experimentación	Decisiones que se toman “por costumbre”, sin evidencia

Regla de oro: Un buen modelo vale cero si no cambia decisiones reales.

Bloque 4: Los enemigos silenciosos de los datos

Más allá de “datos sucios”

- “Mala calidad de datos” no es el único problema que hunde un proyecto
- Hay fallas **estructurales** que pasan una revisión básica de calidad y aun así rompen un modelo
- **No son los sesgos cognitivos que vimos antes** (esos viven en la cabeza de quien decide): estos viven **dentro del dataset**, incluso si nadie tiene intención de discriminar
- Tres enemigos frecuentes, poco visibles para quien no es técnico:

Enemigo	En una frase
Representación	Falta un grupo entero en los datos
Histórico	Los datos repiten decisiones injustas del pasado
Leakage	El modelo “ve” información que no tendrá disponible en la realidad

Enemigo 1: Sesgo de Representación

Definición: el dataset no representa a toda la población que el modelo afectará.

Caso: Reconocimiento Facial (2018)

- Estudio *Gender Shades* (Buolamwini & Gebru, MIT): evaluó los sistemas de Google, Amazon y Microsoft
- **34 % de error** en rostros de mujeres de piel oscura
- **0.7 % de error** en rostros de hombres de piel clara
- Causa: los modelos se entrenaron mayoritariamente con rostros de personas blancas

Impacto real: sistemas de control de acceso que dejan afuera a personas con piel oscura; uso policial que falla en identificar correctamente a personas afrodescendientes.

Caso: Modelos de Crédito

- Un banco entrena su modelo con el historial de clientes que **ya tiene**: mayoritariamente clase media-alta
- El modelo rechaza más solicitudes de clientes de menores ingresos, **aunque sean buen riesgo**
- No es que el algoritmo discrimine a propósito: simplemente no vio suficientes ejemplos de ese grupo

Riesgo para el negocio: discriminación indirecta, mercado no alcanzado, exposición ante el regulador (CMF).

Cómo detectarlo

Red flags: “El modelo funciona bien para el cliente típico” / “Esos grupos son muy pequeños en nuestros datos, no importa”

Test simple: segmentar el dataset por género, edad, zona geográfica, nivel socioeconómico → ¿el modelo funciona igual de bien en todos los segmentos? Si no, hay sesgo de representación.

Enemigo 2: Sesgo Histórico

Definición: el modelo aprende de decisiones humanas del pasado — y si esas decisiones eran injustas, el modelo las repite a escala.

Caso: Amazon Hiring Algorithm (2014–2018)

- Amazon construyó un algoritmo para filtrar CVs, entrenado con 10 años de contrataciones en tecnología
 - Como históricamente se contrataba a más hombres en esas áreas, el algoritmo **aprendió a penalizar a mujeres**
 - Llegó a rechazar CVs que mencionaban “*women’s chess club*” o colegios solo de mujeres
 - Amazon discontinuó el proyecto en 2018, por riesgo reputacional y legal
-

Caso: COMPAS (Sistema de Justicia Criminal, EE.UU.)

- Algoritmo usado para predecir reincidencia, entrenado con datos históricos de arrestos
- El sistema penal históricamente arresta más a población afrodescendiente
- El algoritmo predijo **más reincidencia en ese grupo** — lógica circular: ¿predice crimen, o predice a quién arrestan?

Pregunta sin responder: ¿la variable que usamos para entrenar mide lo que creemos que mide?

Cómo detectarlo

Red flags: “Así lo hemos hecho siempre” / “Usamos el histórico de decisiones, evaluaciones o contrataciones”

Test simple: ¿de dónde vienen los datos de entrenamiento? ¿Esas decisiones humanas pasadas fueron auditadas como justas, o simplemente se asumió que lo eran?

Enemigo 3: Data Leakage

Definición: el modelo usa, durante el entrenamiento, información que **no estará disponible** en el momento real de predecir. Por eso parece perfecto en pruebas y falla en producción.

Caso: Predicción de Fraude

Caso: Deserción de clientes / afiliados

Lo que funciona: usar datos de hace 2-3 meses (uso del producto, contacto con el cliente, comportamiento de pago) para predecir quién se va en los próximos 3 meses.

Lo que NO funciona: incluir como variable “¿ya se retiró?” — eso es exactamente lo que se quiere predecir.

Si el indicador de desempeño es sospechosamente perfecto (>95-99 %), hay que buscar leakage antes de celebrar.

Cómo detectarlo

Pregunta clave: “¿Toda esta información estaría disponible en el momento exacto en que necesitamos predecir?”

Red flags: precisión sospechosamente alta (>95-99 %); el resultado que se predice aparece, de alguna forma, como variable de entrada.

Gobernanza en acción: las 5 preguntas antes de aprobar un proyecto de IA

1. ¿Quién está representado en estos datos? ¿Quién falta?
 2. ¿Estos datos reflejan decisiones justas del pasado, o las repiten?
 3. ¿Hay información aquí que no tendríamos disponible al momento de decidir?
 4. ¿Qué tan limpia y confiable es esta data?
 5. ¿Quién vigila el modelo una vez en producción, y qué pasa si falla?
-

Cuadro de decisión

Pregunta	Sí	Con riesgo	No
¿Grupos representados?	Adelante	Limitar alcance	No aprobar
¿Histórico justo?	Adelante	Auditar y limpiar	No aprobar
¿Sin leakage?	Adelante	Remover variables	No aprobar
¿Datos limpios y monitoreados?	Adelante	Invertir antes de lanzar	No aprobar

Criterio: al menos 3 de 4 deben ser “Sí” o “Con riesgo + plan concreto”.

Actividad — Diagnóstico de Datos (15 min, sin herramientas)

Formen grupos. Piensen en su área o una institución financiera que conozcan y respondan, **en papel o conversando**, sin usar ninguna herramienta de IA:

1. **¿Qué datos generamos hoy que nunca capturamos como información útil?** - Ej.: se registra que un cliente cerró su cuenta, pero no por qué lo hizo - Ej.: se registra la aprobación de un crédito, pero no las razones del rechazo de los que no calificaron
2. **¿Quién no está representado en nuestros datos?** - ¿Solo los clientes que ya compraron un producto? ¿No los que cotizaron y no compraron? - ¿Solo zonas urbanas? ¿Qué pasa con zonas rurales o con menor historial bancario?
3. **Si tuviéramos que auditar un modelo de crédito de nuestra institución, ¿cuál de los 3 enemigos (representación, histórico, leakage) creen que es más probable encontrar, y por qué?**

Compartan sus respuestas con el resto del curso.

Glosario (complemento)

Término	Definición simple
Sesgo de representación	El dataset no incluye a todos los grupos que el modelo afectará
Sesgo histórico	El dataset refleja decisiones injustas del pasado y el modelo las repite
Data Leakage	Información que solo existe <i>después</i> del evento que se quiere predecir, filtrada al entrenamiento

Referencias

- Buolamwini, J., & Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification. *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, 77–91. <http://proceedings.mlr.press/v81/buolamwini18a.html>
- Angwin, J., Larson, J., Mattu, S., & Kirchner, L. (2016). Machine bias. *ProPublica*. <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>
- Dastin, J. (2018). Amazon scraps secret AI recruiting tool that showed bias against women. *Reuters*. <https://www.reuters.com/article/us-amazon-com-jobs-automation-insight-idUSKCN1MK08G>