

# Data Science y Analytics en Servicios Financieros

## Clase 02 – Calidad, Gobernanza y Sesgos en IA

2026-06-24

### Enlaces

-  sebastian.egana@udd.cl
  -  <https://segana.netlify.app>
  -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
  -  <https://github.com/sebaegana>
- 

### Calidad y gobernanza de los datos

#### ¿Por qué importa la calidad de los datos?

- El **valor estratégico** de la información depende de su **calidad y gobernanza**
  - Decisiones erróneas → modelos ineficientes → pérdida de confianza.
  - “*Garbage in, garbage out*” – ningún algoritmo corrige datos defectuosos
- 

#### Dimensiones de la calidad de datos

| Dimensión            | Descripción breve             | Ejemplo                              |
|----------------------|-------------------------------|--------------------------------------|
| <b>Compleitud</b>    | Ausencia de valores faltantes | % de clientes sin RUT o correo       |
| <b>Exactitud</b>     | Concordancia con la realidad  | Dirección o edad correcta            |
| <b>Consistencia</b>  | Coherencia entre sistemas     | Fecha nacimiento <> fecha afiliación |
| <b>Actualización</b> | Vigencia de la información    | Cliente activo con contacto obsoleto |

*Pregunta:* identificar un caso de baja calidad en datos internos o de clientes, por ejemplo, en la industria financiera.

---

## Riesgos de decisiones con datos de mala calidad

- **Operativos:** reprocesos, errores en informes, baja productividad
  - **Financieros:** decisiones de inversión o riesgo erradas
  - **Reputacionales:** pérdida de confianza del cliente o del regulador
  - **Analíticos:** modelos con sesgos o predicciones inconsistentes
- 

## Gobernanza de datos

Conjunto de políticas, roles y procesos que aseguran el uso responsable de los datos.

- Define **roles claros:** propietario, custodio, analista, consumidor
- Establece **procesos** de validación, trazabilidad y acceso
- Impulsa **alineamiento con estrategia** organizacional

*Ejemplo:* catálogo de datos, control de acceso y políticas de retención.

---

## Ética y compliance en el uso de datos

- **Responsabilidad:** tratar los datos como un activo compartido
  - **Privacidad:** cumplir normativas (LGPD, GDPR, Ley 19.628 en Chile)
  - **Transparencia:** explicar decisiones automatizadas
  - **Equidad:** evitar sesgos en IA o analítica predictiva
- 

## Cierre y reflexión

- La **calidad** asegura decisiones confiables.
  - La **gobernanza** garantiza responsabilidad y cumplimiento.
  - La **ética** construye confianza con clientes y sociedad.
-

# Introducción a la IA y sus principios básicos

---

## ¿Qué es (y qué no es) Inteligencia Artificial?

- **IA:** capacidad de sistemas para aprender patrones y tomar decisiones basadas en datos
- **No es:** magia ni conciencia, sino algoritmos que **aprenden de ejemplos**
- Se basa en **estadística, aprendizaje automático y automatización**

*Ejemplo:* un modelo que predice abandono de clientes no “piensa”, solo identifica patrones históricos.

---




Figura 1: Recuperado en: <https://www.orsys.fr/orsys-lemag/es/aprendizaje-automatico-aprendizaje-profundo-ia-diferencias>

---

La IA no es un modelo — es un ecosistema de componentes

Un LLM (Large Language Model) como GPT o Claude es solo una parte del sistema.

Para responder una consulta compleja, se articulan **varios segmentos de IA**:

- **Computer Vision** → detecta y analiza imágenes (objetos, rostros, escenas).
- **OCR (Reconocimiento Óptico de Caracteres)** → extrae texto de imágenes o PDFs.
- **Speech Recognition / TTS** → convierte audio en texto y viceversa.
- **LLM** → interpreta, contextualiza y genera una respuesta en lenguaje natural.
- **Reasoning / Orchestration Layer** → decide qué componentes usar y en qué orden.

Ejemplo

“Subo una foto de un contrato y pregunto de qué trata”

| Etapas | Segmento de IA         | Función                                           | Ejemplo de salida                                                   |
|--------|------------------------|---------------------------------------------------|---------------------------------------------------------------------|
| 1      | <b>Computer Vision</b> | Detecta texto y no una persona o paisaje.         | “Documento detectado”                                               |
| 2      | <b>OCR</b>             | Extrae texto                                      | “Contrato de prestación de servicios...”                            |
| 3      | <b>LLM</b>             | Interpreta, resume cláusulas, responde preguntas. | “Este contrato regula la relación entre la empresa y un proveedor.” |
| 4      | <b>Orquestador</b>     | Coordina                                          | Decide usar OCR → LLM                                               |

- Resultado: “El documento corresponde a un contrato de servicios con fecha de inicio 2024-01-10 entre X y Y.”

Modelos descriptivos vs. predictivos

| Tipo de modelo      | Objetivo              | Ejemplo ejecutivo                           |
|---------------------|-----------------------|---------------------------------------------|
| <b>Descriptivo</b>  | Explica qué ocurrió   | Segmentación de clientes por comportamiento |
| <b>Predictivo</b>   | Anticipa qué ocurrirá | Predicción de egreso o mora                 |
| <b>Prescriptivo</b> | Recomienda acciones   | Sugerir la mejor oferta según propensión    |

## Interpretación de resultados de IA

### Qué significa un “resultado confiable”

- Un modelo **no entrega certezas**, entrega **probabilidades**
  - La confiabilidad depende de calidad de datos, validación del model, comparación entre predicciones y realidad
  - Ejemplo: *modelo de churn predice 80 % → no dice “renunciará”, sino “probabilidad alta de egreso”*
- 

### Predicción y margen de error

Todo modelo tiene un grado de error aceptable según su propósito.

- Se mide con indicadores: *precisión, recall, etc.*
- En contexto ejecutivo → “¿Cuánto confío en este resultado para tomar una decisión?”

Por ejemplo un 90 % de precisión puede ser excelente en marketing, pero insuficiente en salud.

---

### Overfitting explicado de forma ejecutiva

“Cuando el modelo aprende de memoria el pasado y no sabe generalizar al futuro.”

- Se ajusta tanto a los datos históricos que pierde capacidad predictiva
- Síntomas: Resultados casi perfectos en entrenamiento y mal desempeño con nuevos datos
- Solución: validación cruzada, regularización, simplicidad del modelo

*Ejemplo:* modelo que predice bien a clientes antiguos pero falla en nuevos afiliados.

---

## Sesgos en los datos y modelos

### Tipos de sesgos

| Tipo               | Descripción                       | Ejemplo                 |
|--------------------|-----------------------------------|-------------------------|
| <b>Muestreo</b>    | Datos no representan la población | Solo clientes activos   |
| <b>Histórico</b>   | Refleja desigualdades pasadas     | Sesgos en género o edad |
| <b>De medición</b> | Error en cómo se capturan datos   | Encuestas incompletas   |

---

## Ejemplos de sesgos y consecuencias

- **Reclutamiento automatizado:** modelos que excluyen perfiles femeninos por datos históricos
- **Crédito:** mayor probabilidad de rechazo en comunas con bajo historial financiero
- **Salud:** subrepresentación de grupos etarios o regiones

*Impacto estratégico:* decisiones injustas → daño reputacional → pérdida de confianza → riesgo legal.

---

## Cómo mitigar sesgos desde la gestión

- Diversificar fuentes de datos
  - Monitorear resultados por grupo o segmento
  - Revisar métricas éticas además de métricas de performance
  - Incluir equipos interdisciplinarios en revisión de modelos
- 

## Aplicación práctica: decisiones informadas con IA

### Actividad grupal – Interpretando resultados de IA

Caso:

Una AFP aplica un modelo de IA para predecir egresos de afiliados. El modelo entrega una **probabilidad de egreso del 75 %** para un cliente de alto saldo. Los costos de retención estimados: **\$20.000 CLP por cliente**. Los costos de pérdida si egresa: **\$250.000 CLP**.

Instrucciones (20 min)

En grupos, respondan:

1. ¿Vale la pena intervenir al cliente?
2. ¿Qué información adicional pedirían antes de decidir?
3. ¿Qué riesgo asumen si el modelo se equivoca?

Compartir sus reflexiones.

---

## Checklist ejecutivo para líderes

- Validar calidad de los datos usados.
  - Exigir interpretación comprensible de los resultados.
  - Evaluar sesgos potenciales y su impacto.
  - Considerar el costo del error (falso positivo/negativo).
  - Promover decisiones basadas en evidencia, no en intuición.
- 

## Cierre

La Inteligencia Artificial **no reemplaza el juicio humano**, lo potencia.

- Entender sus **principios, límites y sesgos** es clave para liderar con responsabilidad.
- 

## Referencias

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. & Polosukhin, I. (2017). Attention is all you need. Advances in neural information processing systems, 30. <https://arxiv.org/pdf/1706.03762>