

Data Science y Analytics en Servicios Financieros

Clase 02 – Modelos, Calidad e Interpretación

2026-06-30

Enlaces

-  sebastian.egana@udd.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Estructura de la Sesión

Bloque	Duración	Contenido
1	20 min	De los datos a los modelos
2	20 min	Calidad de datos: las 4 dimensiones
3	20 min	Interpretación de resultados
4	10 min	Cierre

Bloque 1: De los datos a los modelos

Puente desde la Clase 01

En la clase anterior establecimos que **toda decisión es una predicción** y que los proyectos exitosos parten desde la decisión, no desde los datos.

Hoy entramos al siguiente nivel: ¿qué hacen los modelos exactamente, cómo se construyen, y cómo se leen sus resultados sin ser técnico?

¿Qué hace un modelo?

Tipo	Objetivo	Ejemplo en banca
Descriptivo	Explica qué ocurrió	Segmentación de clientes por comportamiento de pago
Predictivo	Anticipa qué ocurrirá	Probabilidad de mora en los próximos 90 días
Prescriptivo	Recomienda una acción	Sugerir el producto con mayor propensión de compra

Idea clave: la mayoría de los proyectos de analytics en servicios financieros son predictivos. El prescriptivo es el paso siguiente — y el más difícil de implementar.

La IA no es un modelo — es un ecosistema

Un **LLM** (Large Language Model) como GPT o Claude es solo una parte del sistema.

Para responder una consulta compleja, se articulan varios componentes:

- **Computer Vision** → detecta y analiza imágenes (objetos, documentos, rostros)
- **OCR** → extrae texto de imágenes o PDFs
- **Speech Recognition / TTS** → convierte audio en texto y viceversa
- **LLM** → interpreta, contextualiza y genera respuesta en lenguaje natural
- **Reasoning / Orchestration Layer** → decide qué componentes usar y en qué orden

Ejemplo: “sube una foto de un contrato y pregunta de qué trata”

Etapas	Componente	Función	Salida
1	Computer Vision	Detecta que es un documento, no una foto	“Documento detectado”
2	OCR	Extrae el texto	“Contrato de prestación de servicios...”
3	LLM	Interpreta y resume cláusulas	“Este contrato regula la relación entre X e Y”
4	Orquestador	Coordina el flujo	Decide: OCR → LLM

Pregunta

¿Qué proceso de su área podría beneficiarse de alguno de estos componentes?

Piensen en tareas repetitivas que involucran documentos, imágenes, audio, o texto no estructurado.

Bloque 2: Calidad de datos — las 4 dimensiones

Más allá de “datos sucios”

En la Clase 01 vimos que los **enemigos silenciosos** (representación, histórico, leakage) son problemas estructurales que pasan una revisión básica de calidad.

Pero también existe una capa más operacional: **las dimensiones de calidad** que afectan el día a día de cualquier proyecto de datos.

La diferencia: - Los enemigos silenciosos **rompen el modelo** - Las dimensiones de calidad **erosionan la confianza** en los resultados

Las 4 dimensiones de calidad

Dimensión	Descripción	Ejemplo en banca
Compleitud	Sin valores faltantes	% de clientes sin RUT, correo o fecha de nacimiento
Exactitud	Concordancia con la realidad	Dirección o ingreso declarado vs. realidad
Consistencia	Coherencia entre sistemas	Fecha de nacimiento distinta en core bancario y CRM
Actualización	Vigencia de la información	Cliente activo con teléfono de contacto obsoleto

Pregunta

¿Cuál de estas cuatro dimensiones es el problema más frecuente en su área o empresa?

¿Tienen algún proceso hoy para detectarlo o medirlo?

Riesgos concretos por tipo de falla

Dimensión	Riesgo operativo	Riesgo analítico
Compleitud	Campañas que no llegan al cliente	Modelos entrenados con registros incompletos
Exactitud	Envíos a dirección incorrecta	Variables de entrada que no representan la realidad
Consistencia	Reportes con cifras distintas según la fuente	Joins incorrectos entre tablas, duplicados
Actualización	Gestión de cobranza a contacto equivocado	Modelo entrenado con datos que ya no reflejan el comportamiento actual

Gobernanza: quién hace qué

La gobernanza no es un comité — es un sistema de **roles, procesos y responsabilidades** que asegura que los datos lleguen limpios, a tiempo y con trazabilidad.

Rol	Responsabilidad
Propietario del dato	Define qué significa cada campo y quién puede usarlo
Custodio	Asegura el almacenamiento, acceso y seguridad
Analista / Consumidor	Usa los datos; reporta problemas de calidad

Sin propietario claro → nadie corrige → el problema escala.

Procesos de gobernanza en la práctica

- **Catálogo de datos:** inventario de qué existe, dónde vive, qué significa cada campo
- **Linaje de datos:** trazabilidad desde el origen hasta el modelo o reporte final
- **Control de acceso:** quién puede ver, modificar o exportar cada dataset
- **Política de retención:** cuánto tiempo se guardan datos y bajo qué normativa

Sin estos procesos, una auditoría de la CMF o un incidente de seguridad exponen al banco a riesgo legal y reputacional significativo.

Bloque 3: Interpretación de resultados

¿Qué significa un resultado confiable?

- Un modelo **no entrega certezas** — entrega **probabilidades**
- La confiabilidad depende de tres factores:
 1. Calidad de los datos de entrada
 2. Validación del modelo (¿se probó con datos que no vio?)
 3. Estabilidad en el tiempo (¿sigue funcionando igual 6 meses después?)

Ejemplo: un modelo de churn predice 80 % → no dice “este cliente se irá”, sino “hay alta probabilidad de egreso según los patrones históricos”.

Predicción y margen de error

Todo modelo tiene un grado de error aceptable según su propósito.

Métrica	Qué mide	Cuándo importa más
Precisión	De los que predijo positivo, ¿cuántos realmente lo eran?	Cuando el costo de un falso positivo es alto
Recall	De los positivos reales, ¿cuántos detectó?	Cuando el costo de perder un caso es alto
AUC-ROC	Capacidad discriminatoria general del modelo	Comparación entre modelos

Un 90 % de precisión puede ser excelente en marketing y **completamente insuficiente en detección de fraude**.

Overfitting: cuando el modelo aprende de memoria

“El modelo memorizó el pasado pero no aprendió a generalizar.”

- Se ajusta tanto a los datos históricos que pierde capacidad predictiva con datos nuevos
- **Síntoma más común:** precisión casi perfecta en entrenamiento (98 %) y mediocre en producción (71 %)
- **Causa frecuente:** demasiadas variables, modelo demasiado complejo, dataset pequeño

Analogía: un alumno que memoriza las respuestas del ensayo anterior y reprueba el examen real.

Ética y compliance

El uso de datos y modelos no es solo un problema técnico — tiene implicancias **legales y reputacionales**.

Marco	Alcance	Relevancia para banca chilena
Ley 19.628	Chile — protección de datos personales	Consentimiento para uso de datos de clientes
GDPR	Unión Europea	Aplica si el banco opera o tiene clientes en Europa
LGPD	Brasil — similar al GDPR	Relevante para bancos con operaciones en Brasil

Principios transversales: consentimiento informado, derecho al olvido, explicabilidad de decisiones automatizadas, no discriminación.

Un modelo que discrimina por género o zona geográfica puede cumplir técnicamente con las métricas y aun así ser ilegal.

Pregunta

¿Su organización tiene un proceso para revisar si un modelo discrimina antes de ponerlo en producción?

¿Quién toma esa decisión — el equipo técnico, el área legal, el directorio?

Bloque 4: Cierre

Checklist para líderes

Antes de aprobar el uso de un modelo en producción:

- ¿Los datos usados tienen buena calidad en las 4 dimensiones?
- ¿El modelo fue validado con datos que no vio durante el entrenamiento?
- ¿Se midió el error en distintos segmentos (edad, género, zona)?
- ¿Se consideró el costo asimétrico del error (falso positivo vs. falso negativo)?
- ¿El resultado es explicable a un cliente o al regulador si lo pide?
- ¿Hay un proceso de monitoreo después del lanzamiento?

Cierre

La Inteligencia Artificial **no reemplaza el juicio humano** — lo potencia.

- Entender **qué hace un modelo** permite hacer mejores preguntas al equipo técnico
 - Conocer las **dimensiones de calidad** permite detectar problemas antes de que rompan un proyecto
 - Leer **resultados con criterio** — probabilidades, márgenes de error, costos asimétricos — es la habilidad diferenciadora del líder data-driven
-

Referencias

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30. <https://arxiv.org/pdf/1706.03762>

European Parliament. (2016). General Data Protection Regulation (GDPR). <https://gdpr-info.eu>

Biblioteca del Congreso Nacional de Chile. (1999). Ley 19.628 sobre protección de la vida privada. <https://www.bcn.cl/leychile/navegar?idNorma=141599>