

Data Science y Analytics en Servicios Financieros

Clase 01 – Introducción y Contexto

2026-06-30

Enlaces

-  segana@fen.uchile.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Contexto y motivación

Contexto actual

- El volumen global de datos crece a más de **40 % anual** (IDC, 2024).
 - Sin embargo, solo **~30 %** de las empresas afirma ser realmente *data-driven* (McKinsey, 2023).
 - El valor no está en acumular datos, sino en **transformarlos en decisiones**.
 - La complejidad actual exige modelos predictivos, arquitecturas modernas y procesos guiados por evidencia.
-



Rol de la IA

- La IA permite **extraer patrones, predecir comportamientos y automatizar decisiones**.
- Integra datos estructurados y no estructurados (texto, audio, imágenes, PDFs, transacciones, logs).
- Los modelos actuales (ML + LLMs) permiten:
 - Extraer señales desde fuentes no tradicionales.
 - Recuperar + generar contenido (RAG).
 - Acelerar la **velocidad y calidad** de las decisiones.
- Objetivo central: **reducir incertidumbre** y mejorar resultados.

¿Por qué es difícil ser data-driven?

- No es un problema técnico: es un problema **organizacional y cultural**.
 - Obstáculos frecuentes:
 - Datos dispersos, desordenados o sin gobierno.
 - Falta de claridad en la decisión que se quiere mejorar.
 - Poca alineación entre áreas (TI, riesgo, operaciones, finanzas).
 - Sesgos humanos que dominan la toma de decisiones.
 - Baja adopción de modelos por parte del negocio.
 - Conclusión: ser data-driven requiere **procesos, cultura y diseño**, no solo modelos.
-

Decision science

Instituciones basadas en datos

La diferencia entre decisiones **intuitivas** y decisiones **basadas en datos** es crítica.

Ejemplo cotidiano:

Elegir entre dos ofertas laborales (mayor salario vs. mejor calidad de vida).

Podemos decidir por instinto o mediante una **evaluación sistemática** de factores.

Una organización data-driven hace lo mismo:

- define el problema
- recopila evidencia
- evalúa escenarios
- elige la opción con **mayor retorno esperado**
- reduce el espacio de incertidumbre

Este es el territorio de **Decision Science**.

¿Qué es Decision Science?

La *Decision Science* es el campo interdisciplinario que:

- Combina estadística, economía, psicología, modelos computacionales y negocio.
- Crea procesos estructurados para **mejorar decisiones bajo incertidumbre**.
- Traduce datos + modelos en **acciones concretas** que generan impacto.
- Permite diseñar decisiones que sean:
 - informadas,
 - repetibles,
 - medibles,

- alineadas a objetivos estratégicos.

Idea clave:

Los datos no toman decisiones, las decisiones se diseñan.

Ejemplo cotidiano de decisión

Considera dos opciones:

- **Oferta A:** mayor salario, pero requiere relocalización.
 - **Oferta B:** menor salario, pero mejor equilibrio vida/trabajo.
-

¿Cómo decides?

Puedes:

Decisión intuitiva: Una decisión tomada desde el instinto: rápida, emocional, y dependiente de cómo te sientes en ese momento. No requiere estructura, pero puede ser difícil de justificar o repetir.

Decisión estructurada: Una decisión diseñada: define claramente qué factores importan (salario, familia, transporte, salud) y cómo se relacionan entre sí.

Permite comparar escenarios, pensar en los riesgos y visualizar los compromisos que implica cada alternativa.

Esto mismo escala al mundo financiero: aprobar un crédito, fijar un precio, asignar un portafolio. Todo requiere **criterios, escenarios, riesgo, datos**.

Sesgos más allá de los datos

Incluso con modelos y datos perfectos, los seres humanos tenemos sesgos que afectan la decisión:

- **Confirmation bias:** buscamos información que confirma lo que creemos.
 - **Anchoring bias:** nos quedamos anclados a un valor inicial (ej.: precio en un “cyber”).
 - **Loss aversion:** perder duele más que ganar lo mismo.
 - **Availability heuristic:** sobreestimamos eventos fáciles de recordar (accidentes aéreos).
-

Estos sesgos están presentes en:

- decisiones de riesgo
- inversiones
- evaluación de campañas

- aprobación de créditos

Decision Science busca mitigarlos mediante procesos estructurados.

Sobre la racionalidad limitada

La teoría asume decisiones racionales:

- información completa
 - tiempo infinito
 - sin emociones
 - sin sesgos
-

La realidad es distinta:

1. **Tenemos límites cognitivos.**
2. **Disponemos de información incompleta.**
3. **Operamos bajo presión de tiempo.**
4. **Emociones y riesgo percibido influyen.**

Por eso la toma de decisiones ocurre en un contexto de **racionalidad limitada**, donde los modelos y los datos ayudan a compensar nuestras limitaciones.

El método científico como base

El método científico propone un ciclo estructurado:

1. **Observación**
 2. **Planteamiento de hipótesis**
 3. **Experimentación / Medición**
 4. **Análisis de resultados**
 5. **Conclusión**
-

En Decision Science este ciclo se aplica a decisiones:

- Las hipótesis = propuestas de acción.
- Los experimentos = pilotos, A/B testing, simulaciones.
- El análisis = evidencia cuantitativa sobre qué funciona.

No se trata de “tener razón”, sino de **aprender**.

Toda decisión es una predicción

Cada decisión —en salud, finanzas o negocios— implica una predicción:

- Aprobar un crédito → predicción de pago/no pago.
 - Determinar un precio → predicción de demanda.
 - Asignar un portafolio → predicción de retornos y riesgos.
 - Aceptar un trabajo → predicción de bienestar futuro.
-

Una buena decisión requiere:

- datos
- modelos
- escenarios
- estimar incertidumbre
- medir impacto

El reto no es decidir, sino predecir mejor. Y hacerlo de forma sistemática.

Framework organizacional

Framework de trabajo

El enfoque de **Decision Science** propone un ciclo sistemático:

1. Definir el problema

- ¿Qué decisión queremos mejorar?
- ¿Qué significa “éxito” para negocio/riesgo/operaciones?

2. Reunir y analizar datos

- Fuentes internas y externas.
 - Calidad, disponibilidad, relevancia.
 - Primeras señales y patrones.
-

3. Desarrollar y evaluar alternativas

- Distintos modelos, escenarios, políticas, precios.
- ¿Qué ocurre si...?

4. Seleccionar e implementar soluciones

- La alternativa con mejor relación riesgo-retorno.
- Integración al flujo productivo.
- Medición de impacto real.

Este ciclo convierte datos → modelos → decisiones → resultados.

The Decision Stack

Para que los datos generen impacto, se debe comenzar **arriba**, en la decisión:

1. Decision

- ¿Qué decisión específica vamos a mejorar?

2. Objective

- ¿Qué significa “mejor”?
- ¿Mayor retorno? ¿Menor riesgo? ¿Mayor conversión?

3. Alternatives

- Distintas políticas, reglas, modelos, precios.
-

4. Uncertainty

- ¿Qué no sabemos?
- ¿Cómo lo cuantificamos?

5. Models

- Herramientas para reducir incertidumbre.

6. Data

- Datos como insumo, no como punto de partida.

7. Action

- Implementación y monitoreo.

Idea clave:

Los proyectos exitosos empiezan por la **decisión**, no por los datos.

Triaging y calidad de datos

Debemos partir por priorizar qué datos vale la pena usar, limpiar es integrar antes del proceso de analítico:

¿Qué datos importan realmente?

- ¿Son relevantes para la decisión?
 - ¿Representan el comportamiento actual?
 - ¿Se pueden usar legal y operacionalmente?
-

Chequeos de calidad

- Porcentaje de valores perdidos (missingness).
 - Rango válido de variables (edad, ingresos, tasas).
 - Detección de outliers.
 - Actualización y frescura de los datos.
-

Triaging (priorización)

- No todos los datos valen la pena.
- La clave es priorizar los datos con:
 - impacto potencial
 - disponibilidad
 - costo razonable
 - alineación con la decisión

Buenos datos → buenos modelos → mejores decisiones.

¿Por qué fallan los proyectos data-driven?

Las causas más comunes:

Problema	Descripción
Problema mal definido	Modelo construido sin una decisión clara asociada
Métricas de éxito poco claras	Éxito técnico no coincide con el éxito de negocio
Mala calidad de datos	Datos desordenados, incompletos o irrelevantes
Desconexión entre negocio y analytics	Poco buy-in, alineación débil, expectativas poco realistas
Modelos que no se implementan	Quedan en notebooks y no llegan a producción
Falta de cultura de experimentación	Decisiones que se toman “por costumbre”, sin evidencia

Regla de oro: Un buen modelo vale cero si no cambia decisiones reales.

Fundamentos estadísticos esenciales

Conceptos clave:

- Tendencia central (media, mediana, moda)
- Dispersión (varianza, desviación estándar)
- Correlaciones entre variables
- Incertidumbre y variabilidad

Idea central:

La estadística no busca certezas, sino **cuantificar incertidumbre** para tomar mejores decisiones.

Medidas de éxito

Un proyecto de datos no es exitoso solo porque “el modelo funciona”. Antes de comenzar, se deben acordar **criterios de éxito**:

Desempeño técnico

- Accuracy, AUC, precision, recall, MAE, RMSE.
- ¿Qué métrica importa para la decisión?

Tiempo

- ¿Llegó el modelo cuando el negocio lo necesitaba?

Costo

- Eficiencia de recursos, infraestructura, licencias, horas hombre.

Calidad

- Reproducibilidad, claridad del código, documentación.

Impacto en el negocio

- Rentabilidad, reducción de riesgo, eficiencia operacional.

Un modelo sin impacto es solo un análisis interesante.

Promedio, varianza y correlación

Promedio (media): Representa el “centro” de los datos.

Varianza / Desviación estándar: Miden la variabilidad.

Correlación: Indica si dos variables se mueven juntas.

Cuidado:

Correlación no implica causalidad. Que dos series se muevan juntas no significa que una cause la otra.

Utilización de datos

Jack Maple y COMPSTAT Center



Figura 1: Recuperada en: <https://www.nydailynews.com/2013/09/16/hamill-bill-de-blasio-says-bill-bratton-on-short-list-to-be-police-commissioner>

Tiempo promedio de hospitalización

En un caso simple, podríamos pensar en el promedio de días que pasa cada paciente por alguna patología en particular.

Tenemos los siguientes datos de altas de pacientes con neumonía y queremos predecir el tiempo promedio de hospitalización en días:

```
tiempo <- c(2,3,1,5,7,8,9,3,4,6,2,10,11,7,5,4,12,8,9,6)
alta    <- c(1,1,1,1,1,0,0,1,1,1,1,0,0,1,1,1,0,1,1,1)
```

Acá la censura corresponde a los pacientes que no han sido dados de alta (alta = 0).

Tabla 1: conteos: total, eventos (DELTA=1), censuras (DELTA=0)

Total	Eventos_DELTA1	Censuras_DELTA0	Proporcion_evento
20	15	5	0.75

Tabla 2: Resumen global de TCC (días)

n	min	mean	mean_obs	sd	median	max
20	1	6.1	4.8	3.161	6	12

Veamos el análisis de Weibull para estos datos:

Tabla 3: Parámetros Weibull 2P

Caso	shape (k)	scale ()
Con censura	1.5848	7.8569

Tabla 4: Mediana, media y percentiles t_p ($p=0.1, 0.5, 0.9$)

Caso	Mediana	Media	$p=0.1$	$p=0.5$	$p=0.9$
Con censura	6.2347	7.0506	1.8993	6.2347	13.2985


LATAM Airlines Group (LTM.SN)

2018–actualidad

Último cierre: \$26,97 CLP (2026-06-26)



Ventana 2020–2021





Machine Learning en la práctica

¿Cómo se hace ML en la práctica?

1. Hacer una pregunta
 2. Recolectar y explorar datos
 3. Limpiar y transformar atributos
 4. Seleccionar algoritmos
 5. Entrenar modelos
 6. Evaluar resultados
 7. Usar las respuestas
-


Precauciones clave

- Umbrales de decisión importan más que la accuracy
 - La matriz de confusión define *lo que cuesta equivocarse*
 - Decisiones deben basarse en **beneficios y costos reales**, no en métricas abstractas
 - **Regulación:** crédito, salud, seguros → modelos deben ser explicables
-

Error Tipo I vs Tipo II


Falso Positivo (Tipo I)

- Detecta algo que *no está*
- “¡Está embarazado!” (cuando no lo está)



Falso Negativo (Tipo II)

- No detecta algo que *sí está*
- “No está embarazada” (cuando sí lo está)



Chihuahua o Cupcake



Algunos patrones visuales engañan tanto a humanos como a modelos.
Lo “obvio” no siempre es obvio.




Detector de nieve

Classification: Wolf or a Husky?



Un modelo entrenado solo con “fotos nevadas” aprende a detectar *nieve*, no *perros*.
Los sesgos del dataset se traducen en errores sistemáticos.

Interpretabilidad vs Exactitud



Más exactitud suele implicar menos interpretabilidad.

La decisión depende del **riesgo**, **regulación**, y **confianza del negocio**.

Muestreo: Entrenamiento vs. Prueba

La división de los datos en **Train Set** y **Test Set** (típicamente 70 % / 30 %) es una herramienta fundamental para **evaluar la capacidad real de generalización** del modelo.

¿Qué pasa si no dividimos?

- El modelo se entrena y evalúa con los **mismos datos**.
 - Puede aprender patrones verdaderos y **también ruido**.
 - En la práctica, “parece perfecto”... pero sólo dentro de su entrenamiento.
-

¿Qué aporta el Test Set?

- Muestra cómo se comporta el modelo en **datos nunca vistos**.
 - Si el error en train es bajo pero en test es alto → **overfitting detectado**.
 - Si ambos errores son similares → el modelo está “just right”.
-




Imagen	Interpretación	Conexión con Train/Test
High bias / underfit	Modelo demasiado simple	Alto error en train y test
Just right	Generaliza bien	Errores similares y bajos
High variance / overfit	Memoriza ruido	Train muy bueno, Test muy malo

Idea clave

El Test Set es un muestreo independiente que nos alerta cuando el modelo se está sobreadaptando.

Sin él, nunca veríamos la diferencia entre “just right” y “overfit”.

Machine Learning no siempre es accionable

“Esencialmente, todos los modelos están equivocados... algunos sirven.”

— G.E.P. Box

No todo modelo genera impacto:

- puede no implementarse
 - puede no ser interpretable
 - puede ser demasiado caro
 - puede ser poco confiable
-

Incertidumbre y modelos

Incertidumbre y confianza

Medir incertidumbre

En análisis de datos, la incertidumbre **no se elimina**, se **cuantifica**.

- Toda predicción tiene un rango posible de resultados.
- Usamos:
 - intervalos de confianza
 - desviaciones estándar
 - bandas de predicción
 - distribuciones completas

Por qué importa

- Una decisión robusta no se basa solo en “el número esperado”.
- Se basa en entender:
 - qué tan incierto es el resultado
 - qué tan sensible es a los supuestos
 - qué tan grave es un error de predicción

La confianza no proviene de la certeza, sino de entender el riesgo.

Simulaciones de Monte Carlo

Una simulación busca reproducir **posibles futuros** bajo incertidumbre.

¿Cómo funciona?

- Se define un modelo (ventas, precios, costos, retornos...)
- Se asignan distribuciones a las variables inciertas.
- Se generan miles de escenarios con muestreo aleatorio.
- Se obtiene una distribución de resultados.

¿Para qué sirve?

- Evaluar riesgo y probabilidad de pérdidas.
- Analizar sensibilidad del negocio.
- Comparar alternativas bajo incertidumbre.
- Comprender “colas” y eventos extremos.

No predice un futuro, sino **miles de futuros posibles**.

Tipos de modelos

Modelos de regresión

- Variable objetivo: numérica/continua
- Ejemplos:
 - predicción de precio de activo
 - forecasting de demanda
 - estimación de ingresos

Modelos de clasificación

- Variable objetivo: categórica/discreta
- Ejemplos:
 - default vs. no default
 - fraude vs. no fraude
 - churn vs. no churn

Clustering (no supervisado)

- Identifica grupos o patrones sin etiquetas
- Ejemplos:
 - segmentación de clientes
 - patrones de comportamiento transaccional

Métricas de modelos

Clasificación

Métrica	Descripción
Accuracy	Proporción de aciertos totales.
Precision	Proporción de los predichos positivos que eran realmente positivos.
Recall	Proporción de los verdaderos positivos que fueron correctamente detectados.
F1 Score	Media armónica entre precision y recall; balancea ambos.
AUC-ROC	Capacidad global del modelo para discriminar entre clases (área bajo la curva ROC).

Regresión

Métrica	Descripción
MAE	Error absoluto promedio.
RMSE	Penaliza más los errores grandes.
MAPE	Error porcentual promedio.
R²	Varianza explicada (no siempre es una buena métrica).

Matriz de confusión

La matriz de confusión resume el desempeño de un modelo de clasificación:

- **TP:** verdaderos positivos
- **FP:** falsos positivos
- **FN:** falsos negativos
- **TN:** verdaderos negativos

Elegir la métrica correcta depende del costo del error.

		Ground truth		
		+	-	
Predicted	+	True positive (TP)	False positive (FP)	Precision = $TP / (TP + FP)$
	-	False negative (FN)	True negative (TN)	
		Recall = $TP / (TP + FN)$		Accuracy = $(TP + TN) / (TP + FP + TN + FN)$

[Revisar](#)

En detalle

- La **precision** importa cuando un falso positivo es muy costoso.
 - El **recall** importa cuando un falso negativo es lo más grave.
-

Ejemplos

Churn

Etapas	Error más costoso	Métrica clave	Explicación
Screening de churn	Falso Negativo	Recall	Perder un cliente real suele ser muy costoso para el negocio.
Intervención costosa (beneficios/bonos)	Falso Positivo	Precisión	No quieres gastar recursos en clientes que igual se quedarían.

Salud

Enfermedad	Etapas	Error más costoso	Métrica clave	Explicación
Cáncer	Detección inicial	Falso Negativo	Recall	Dejar sin detectar un cáncer puede costar la vida.
VIH	Screening inicial	Falso Negativo	Recall	No detectar un caso aumenta contagio y agrava la salud.
VIH	Confirmatorio	Falso Positivo	Precisión	Diagnóstico erróneo causa daño psicológico y social.

Montecarlo aplicado a Finanzas

Aplicación en evaluación de proyectos

En el caso de proyectos, podemos realizar un análisis de carácter estocástico, lo que implica asumir que alguna de las variables no es conocida pero sí que puede estar situada dentro de algunos parámetros.

- Veamos el siguiente ejemplo: Una empresa está evaluando la introducción de un nuevo producto y desea conocer la probabilidad que obtenga pérdidas. Para cumplir dicho propósito lo contrata a usted para construir un modelo financiero del negocio.

Después de realizar la debida investigación, usted decide construir una simulación de Monte Carlo que le permita generar la distribución de probabilidad de las utilidades del negocio, modelando separadamente los ingresos y los costos totales, considerando los siguientes elementos:

Por el lado de los ingresos totales, se considerarán tres escenarios (A, B y C) para el precio y la cantidad, los cuales aparecen descritos en la siguiente tabla:

Variable	A	B	C
Precio	12	13	16
Cantidad	110	100	80
Probabilidad	1/4	1/2	1/4

En el caso de los costos totales, los costos fijos son iguales a \$150 y los costos variables unitarios son constantes y son modelados usando una distribución triangular con los siguientes parámetros:

Parámetro	Valores
Valor mínimo	9
Valor máximo	13
Moda	11

Resultado


Código

```
library(tidyverse)
library(triangle)
#set.seed(1234567)

reps = 10000
utilidad = matrix(NA, nrow = reps, ncol = 1)
for (i in 1:reps) {
  x = sample(c("A","B","C"), 1, replace = TRUE, prob = c(1/4, 1/2, 1/4))
  if (x == "A") {
    precio = 12
    cantidad = 110
  }
  else if (x == "B") {
    precio = 13
    cantidad = 100
  }
  else {
    precio = 16
    cantidad = 80
  }
  costo_variable_unitario = rtriangle(1, 9, 13, 11)
  costo_fijo = 150
  utilidad[i] = (precio - costo_variable_unitario)*cantidad - costo_fijo
}

utilidad <- data.frame(utilidad)
```

¿Pérdidas?



```
[1] "Prob(utilidad<0) = 0.31"
```

Utilidades

```
[1] "Valor esperado utilidad = 76.65"
```

IA y Mercados financieros

Hipótesis de los Mercados Eficientes

Los mercados financieros procesan información constantemente: precios, noticias, reportes, expectativas macro, señales técnicas.

La **Hipótesis de los Mercados Eficientes (EMH)** propone que los precios ya reflejan la información disponible.

Sin embargo:

- La IA puede analizar grandes volúmenes de datos
- detectar patrones no lineales,
- extraer señal de texto, imágenes y variables alternativas

¿Puede la IA “ganarle al mercado”? La respuesta depende de **qué tan eficiente sea el mercado**.

[Visitar nofl.ai](http://nofl.ai)

EMH: Forma débil

La forma débil sostiene que:

- Los precios actuales incorporan TODA la información histórica (precios, retornos, volumen).

Implicancias:

- El análisis técnico no debería generar retornos anormales persistentes.
- Los precios siguen un **random walk**.
- No existe memoria temporal útil para predecir retornos futuros.

En la forma débil, la IA compite por micro-ineficiencias.

EMH: Forma semi-fuerte

La forma semi-fuerte sostiene que:

- Los precios incorporan **toda la información pública**, como:
 - noticias
 - reportes corporativos
 - estados financieros
 - indicadores macro

Por lo tanto:

- Ningún análisis basado en información pública debería generar alfa consistente.

Conclusión: ventaja informacional de corto plazo, no necesariamente un alfa sostenible.

EMH: Forma fuerte

La forma fuerte sostiene que:

- Los precios reflejan TODA la información, incluso la **información privada** (insider).

Implicancias:

- Nadie podría obtener retornos superiores de forma consistente
- Incluso información privilegiada estaría incorporada en el precio
- Casi cualquier ventaja desaparecería instantáneamente

Evidencia empírica:

- Casos de insider trading demuestran que la forma fuerte NO se cumple
- Hay filtraciones, anomalías y eventos previsibles de corto plazo

En mercados muy eficientes, la IA es más útil para “vigilar” que para “ganar”.

IA y eficiencia de mercado

En la práctica:

- La IA mejora la velocidad de procesamiento.
- Reduce la fricción informacional.
- Permite extraer señales de datos alternativos:
 - imágenes satelitales
 - tráfico marítimo
 - sensores
 - datos de movilidad
 - comportamiento digital

Pero también:

- Si todos usan IA, las ventajas se vuelven **transitorias**
- La “carrera armamentista” entre agentes reduce el alfa
- La eficiencia aumenta → el alfa disminuye

Conclusión:

La IA no garantiza ganarle al mercado, pero sí **mejora la calidad de las decisiones** en inversión, riesgo y operación.

IA Generativa

¿Qué es la IA Generativa?

- **IA (Artificial Intelligence):** Sistemas capaces de realizar tareas que normalmente requieren inteligencia humana.
- **IA Generativa:** Modelos capaces de *crear* contenido nuevo — texto, imágenes, audio, video, código — a partir de patrones aprendidos.
- La IA generativa **predice patrones** para producir contenido original, no los copia.

IA y algoritmos:

- Los algoritmos clásicos siguen reglas fijas.
 - En IA, **las reglas son aprendidas por el modelo** y pueden mejorar con más datos.
-

Innovaciones clave en la historia de la IA

1. **Cloud computing**
→ Datos + cómputo a escala global.
2. **GANs**
→ Imágenes fotorrealistas.
[Ver ejemplo](#)
3. **Transformers**
→ Comprensión profunda del lenguaje.
[Paper original](#)
4. **RLHF**
→ Modelos ajustados con retroalimentación humana.
5. **Midjourney / Stable Diffusion / GPT-4**
→ Multimodalidad y creatividad avanzada.






Figura 2: Recuperado de: Curso *Generative AI for Business*, DataCamp

La IA no es un modelo — es un ecosistema

Un LLM (GPT, Claude, Llama) es solo una parte del sistema.

Para responder una consulta compleja, se coordinan múltiples componentes:

- **Computer Vision:** detecta objetos/escenas en imágenes.
- **OCR:** extrae texto de imágenes y PDFs.
- **Speech Recognition / TTS:** transforma audio en texto y viceversa.
- **LLM:** interpreta y genera respuestas en lenguaje natural.
- **Orchestration Layer:** decide qué módulos usar y en qué orden.



¿Qué es un LLM?

Un **Large Language Model** es un modelo entrenado con enormes cantidades de texto para:

- predecir la siguiente palabra,
- generar contenido coherente,
- comprender contextos complejos,
- producir texto, código, explicaciones,
- razonar de manera estadística.

Un LLM **no “entiende” el mundo**, modela patrones del lenguaje para generar la respuesta más probable.

Cultura de experimentación

Experimentación en organizaciones

La experimentación es un pilar del enfoque **Decision Science**

Según Harvard Business Review:

- Las decisiones estratégicas mejoran cuando se **prueban hipótesis**
- Las organizaciones exitosas experimentan continuamente:
 - nuevos precios
 - nuevas políticas
 - nuevas interfaces
 - nuevas estrategias de riesgo
 - nuevos modelos

Si no experimentas, **adivinas**. La evidencia supera la intuición

Por qué experimentamos: ejemplos ilustrativos

Epigenética en ratones

- Los cambios observados no se deben a mutaciones, sino a modificaciones heredables de expresión genética.
 - ¿Por qué usar ratones?
→ Permiten experimentación rápida, controlada y repetible.
 - Lección: para entender un sistema complejo, hay que **experimentar**.
-

NASA vs. SpaceX

- NASA: diseño orientado a minimizar el riesgo antes del vuelo.
→ Costos extremadamente altos.
 - SpaceX: filosofía de **iterar rápido**, fallar barato, aprender. → Costo por lanzamiento ~67M vs. >4B del SLS (Space launch system).
 - La innovación requiere un ciclo **prueba → error → ajuste → repetición**.
-

Cultura test-and-learn

Una cultura de experimentación incluye:

Etapas	Elementos clave
Hipótesis claras	¿Qué queremos probar? ¿qué variable queremos mover?
Experimentos controlados	Pilotos, grupos de control, pruebas A/B
Medición rigurosa	Definir métricas antes del experimento, analizar efecto causal y no solo correlaciones
Aprendizaje estructurado	Documentar resultados, ajustar políticas y modelos

La experimentación convierte organizaciones rígidas en organizaciones adaptativas.